

Ανίχνευση Ανεπιθύμητων Μηνυμάτων (SMS Spam Detection)



ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΕΙΡΑΙΩΣ

Τμήμα Ψηφιακών Συστημάτων

Πρόγραμμα Μεταπτυχιακών Σπουδών «Πληροφορικά Συστήματα και Υπηρεσίες»

Ειδίκευση «Μεγάλα Δεδομένα και Αναλυτική»

Μάθημα «Εξόρυξη και Προετοιμασία Δεδομένων»

Ακαδημαϊκό έτος 2025-2026

Επιβλέπων Καθηγήτρια

Κυρία Μαρία Χαλκίδη

Φοιτητές

Όνομα	Επώνυμο	Αριθμός Μητρώου	Email
Antonios	Papakonstantinou	me25028	antonhspap@icloud.com
Dimitrios	Kostiris	me25021	dimkostir@gmail.com

Contents

1. Εισαγωγή: Καθορισμός προβλήματος και στόχων	3
2. Δεδομένα: Περιγραφή δεδομένων και βημάτων προετοιμασίας	4
2.1 Μελέτη δείγματος κειμένων: θόρυβος και μοτίβα	6
3. Μέθοδοι: Προεπεξεργασία κειμένου	7
3.1 Εξαγωγή χαρακτηριστικών: TF-IDF	8
3.2 Μοντέλα: Βασικά, Ensemble και Deep Learning	9
4. Αποτελέσματα: Μετρήσεις, γραφήματα και ανάλυση σφαλμάτων	10
4.2 Αποτελέσματα Cross-Validation (Stratified 5-Fold):.....	11
.....	11
5. Συμπέρασμα: Ευρήματα και προτάσεις για μελλοντική εργασία	12

1. Εισαγωγή: Καθορισμός προβλήματος και στόχων

Η ανεπιθύμητη αλληλογραφία (spam) στα SMS αποτελεί ένα κλασικό πρόβλημα ταξινόμησης κειμένου, με πρακτική σημασία για την προστασία των χρηστών από απάτες, παραπλανητικές διαφημίσεις και κακόβουλες ενέργειες. Στόχος της εργασίας είναι η δυαδική ταξινόμηση μηνυμάτων SMS σε δύο κατηγορίες: ham (κανονικά) και spam (ανεπιθύμητα).

Αρχικά πραγματοποιούμε μελέτη της δομής και της κατανομής του συνόλου δεδομένων, εντοπίζοντας πιθανή ανισορροπία κλάσεων. Στη συνέχεια, εφαρμόζουμε καθαρισμό και προεπεξεργασία κειμένου, εξάγουμε αριθμητικά χαρακτηριστικά (TF-IDF) και εκπαιδεύουμε και στη συνέχεια συγκρίνουμε μοντέλα μηχανικής μάθησης.

Τέλος, αξιολογούμε τα μοντέλα με πολλαπλές μετρικές (accuracy, precision, recall, F1) και πίνακες σύγχυσης, ενώ χρησιμοποιούμε και cross-validation για πιο αξιόπιστη εκτίμηση.

Η σύγκριση περιλαμβάνει βασικά μοντέλα (Logistic Regression, Naive Bayes), προχωρημένα ensemble μοντέλα (Random Forest, XGBoost) και ένα πείραμα deep learning (LSTM), ώστε να διερευνηθεί η επίδραση διαφορετικών προσεγγίσεων στην ανίχνευση spam.

2. Δεδομένα: Περιγραφή δεδομένων και βημάτων προετοιμασίας

Χρησιμοποιήθηκε το σύνολο δεδομένων SMS Spam Collection από το UCI Machine Learning Repository. Το dataset περιέχει SMS μηνύματα με ετικέτα ham ή spam.

Θα το βρείτε εδώ: <https://archive.ics.uci.edu/dataset/228/sms+spam+collection>


Καθώς και στον παραδοτέο φάκελο της εργασίας μας.

Δομή dataset:

Χαρακτηριστικά	Τιμή
Πλήθος δειγμάτων	5572
Στήλες	2 (label, text)
Τύποι δεδομένων	object (κατηγορία + κείμενο)
Missing values	0 (σε label και text) , δεν υπάρχουν δηλαδή

Κατανομή κατηγοριών (ανισορροπία κλάσεων):

Κατηγορία	Πλήθος	Ποσοστό
ham	4825	86.59%
spam	747	13.41%



Σχήμα 1. Κατανομή κατηγοριών (ham vs spam).

Η έντονη ανισορροπία κλάσεων στο dataset (πολύ περισσότερα ham από spam) σημαίνει ότι η μετρική της ακρίβειας (accuracy) από μόνη της μπορεί να είναι παραπλανητική.

Το **accuracy** μετρά το ποσοστό των συνολικά σωστών προβλέψεων, όμως σε ένα imbalanced σύνολο δεδομένων ένα μοντέλο μπορεί να πετύχει υψηλή accuracy ακόμη και αν προβλέπει σχεδόν τα πάντα ως ham. Έτσι, μπορεί να φαίνεται ότι αποδίδει καλά, ενώ στην πραγματικότητα αποτυγχάνει στον βασικό στόχο της εργασίας, δηλαδή την ανίχνευση των spam μηνυμάτων.

Για τον λόγο αυτό δίνουμε ιδιαίτερη έμφαση στις μετρικές precision, recall και F1-score για την κλάση spam.

1. Η **precision** (για spam) δείχνει από όλα τα μηνύματα που το μοντέλο χαρακτήρισε ως spam, πόσα ήταν πράγματι spam, άρα συνδέεται άμεσα με τα False Positives (κανονικά μηνύματα που χαρακτηρίστηκαν λανθασμένα ως spam).
2. Η **recall** (για spam) δείχνει από όλα τα πραγματικά spam πόσα εντοπίστηκαν σωστά, άρα συνδέεται με τα False Negatives (spam που πέρασαν ως ham).
3. Το **F1-score** συνδυάζει precision και recall σε μία ενιαία τιμή, αποτυπώνοντας πιο ισορροπημένα την απόδοση όταν μας ενδιαφέρει ταυτόχρονα και η αποφυγή ψευδών συναγερμών και η αποτελεσματική ανίχνευση spam.

Επιπλέον, χρησιμοποιούμε stratified train και test split ώστε το σύνολο εκπαίδευσης και το σύνολο ελέγχου να διατηρούν την ίδια αναλογία ham και spam.

Με αυτόν τον τρόπο αποφεύγουμε περιπτώσεις όπου ένα τυχαίο split θα οδηγούσε σε υπερβολικά λίγα (ή πολλά) spam στο test set, κάτι που θα έκανε τις μετρικές μη αξιόπιστες.

Αντίστοιχα, εφαρμόζουμε stratified cross-validation για πιο σταθερή και αξιόπιστη αξιολόγηση, καθώς η απόδοση του μοντέλου εκτιμάται σε πολλαπλά διαφορετικά splits, διατηρώντας κάθε φορά την αναλογία κλάσεων. Αυτό μας επιτρέπει να συγκρίνουμε τα μοντέλα με μεγαλύτερη σιγουριά, αξιολογώντας τόσο το μέσο επίπεδο απόδοσης όσο και τη μεταβλητότητά τους.

2.1 Μελέτη δείγματος κειμένων: θόρυβος και μοτίβα

Η ποιοτική και ποσοτική διερεύνηση κειμένων έδειξε ότι τα spam μηνύματα περιέχουν συχνά κλήσεις για δράση (π.χ. 'reply', 'text', 'call'), χρηματικά ποσά, κωδικούς, έντονα κεφαλαία και συνδέσμους. Αντίθετα, τα ham έχουν πιο φυσικό καθημερινό λεξιλόγιο.

```
=== Δείγμα HAM ===
1. If i not meeting u all rite then i'll go home lor. If u dun feel like comin it's ok.
2. I.ll always be there, even if its just in spirit. I.ll get a bb soon. Just trying to be sure i need it.
3. Sorry that took so long, omw now
4. I thk 50 shd be ok he said plus minus 10.. Did u leave a line in between paragraphs?
5. Dunno i juz askin cos i got a card got 20% off 4 a salon called hair sense so i tot it's da one u cut ur hair.

=== Δείγμα SPAM ===
1. Summers finally here! Fancy a chat or flirt with sexy singles in yr area? To get MATCHED up just reply SUMMER now. Free 2 Join. OptOut txt STOP Help08714742804
2. This is the 2nd time we have tried 2 contact u. U have won the 750 Pound prize. 2 claim is easy, call 08718726970 NOW! Only 10p per min. BT-national-rate
3. Get ur 1st RINGTONE FREE NOW! Reply to this msg with TONE. Gr8 TOP 20 tones to your phone every week just £1.50 per wk 2 opt out send STOP 08452810071 16
4. Ur cash-balance is currently 500 pounds - to maximize ur cash-in now send GO to 86688 only 150p/msg. CC: 08718720201 PO BOX 114/14 TCR/W1
5. Last Chance! Claim ur £150 worth of discount vouchers today! Text SHOP to 85023 now! SavaMob, offers mobile! T Cs SavaMob POBOX84, M263UZ. £3.00 Sub. 16
```

Σχήμα 2. Ενδεικτικά δείγματα μηνυμάτων ham και spam.

Ποσοτική καταγραφή μοτίβων θορύβου (ποσοστά ανά κατηγορία):

Μοτίβο	Ham	Spam
URLs	ham: 0.04%	spam: 14.32%
Πολλά ψηφία (>=6)	ham: 0.81%	spam: 83.00%
Έντονα κεφαλαία (>=10)	ham: 6.34%	spam: 66.27%

...	has_url	has_many_digits	has_uppercase_emphasis
label			
ham	0.04	0.81	6.34
spam	14.32	83.00	66.27

Σχήμα 3. Πίνακας ποσοστών μοτίβων (URLs/αριθμοί/κεφαλαία) ανά κατηγορία.

3. Μέθοδοι: Προεπεξεργασία κειμένου

Η προεπεξεργασία κειμένου στοχεύει στη μείωση του θορύβου και στη διατήρηση της πληροφορίας που είναι χρήσιμη για την ταξινόμηση.

Εφαρμόστηκε μια ακολουθία βημάτων καθαρισμού και κανονικοποίησης:

- Μετατροπή σε πεζά (lowercase).
- Αφαίρεση URLs και (όπου υπάρχουν) HTML tags.
- Αφαίρεση σημείων στίξης και ειδικών χαρακτήρων.
- Αφαίρεση extra κενών.
- Αφαίρεση stopwords (αγγλικής γλώσσας).
- Lemmatization, για μετατροπή λέξεων στη βασική τους μορφή (lemma).

Μετά την εφαρμογή των παραπάνω, δημιουργήθηκε νέο πεδίο κειμένου (preprocessed_text), το οποίο χρησιμοποιήθηκε στα επόμενα βήματα.

```
... [nltk_data] Downloading package stopwords to /root/nltk_data...  
[nltk_data]   Unzipping corpora/stopwords.zip.  
  
--- Sample 0 (ham) ---  
ORIGINAL: Go until jurong point, crazy.. Available only in bugis n great world la e buffet... Cine there got amore wat...  
CLEANED:  go jurong point crazy available bugis n great world la e buffet cine got amore wat  
  
--- Sample 2 (spam) ---  
ORIGINAL: Free entry in 2 a wkly comp to win FA Cup final tkts 21st May 2005. Text FA to 87121 to receive entry question(std txt rate)T&C's apply 08452810075over18's  
CLEANED:  free entry 2 wkly comp win fa cup final tkts 21st may 2005 text fa 87121 receive entry questionstd txt ratetcs apply 08452810075over18s  
  
--- Sample 4 (ham) ---  
ORIGINAL: Nah I don't think he goes to usf, he lives around here though  
CLEANED:  nah dont think goes usf lives around though
```

Σχήμα 4. Παράδειγμα πριν/μετά τον καθαρισμό κειμένου.

```
--- Sample 0 (ham) ---  
CLEANED:      go jurong point crazy available bugis n great world la e buffet cine got amore wat  
LEMMATIZED:   go jurong point crazy available bugis n great world la e buffet cine got amore wat  
  
--- Sample 2 (spam) ---  
CLEANED:      free entry 2 wkly comp win fa cup final tkts 21st may 2005 text fa 87121 receive entry questionstd txt ratetcs apply 08452810075over18s  
LEMMATIZED:   free entry 2 wkly comp win fa cup final tkts 21st may 2005 text fa 87121 receive entry questionstd txt ratetcs apply 08452810075over18s  
  
--- Sample 4 (ham) ---  
CLEANED:      nah dont think goes usf lives around though  
LEMMATIZED:   nah dont think go usf life around though
```

Σχήμα 5. Παράδειγμα CLEANED vs LEMMATIZED.

3.1 Εξαγωγή χαρακτηριστικών: TF-IDF

Για την αναπαράσταση του κειμένου σε αριθμητική μορφή χρησιμοποιήθηκε TF-IDF.

Η λογική του TF-IDF είναι να δίνει μεγαλύτερο βάρος σε λέξεις που εμφανίζονται συχνά σε ένα συγκεκριμένο μήνυμα, αλλά είναι σχετικά σπάνιες στο σύνολο των μηνυμάτων.

Χρησιμοποιήθηκαν unigrams και bigrams (`ngram_range=(1,2)`) και περιορίστηκε το λεξιλόγιο στα 5000 πιο σημαντικά χαρακτηριστικά. Τα δεδομένα χωρίστηκαν σε train και test με stratified split (80/20) λόγω ανισορροπίας κλάσεων.

Στοιχείο	Τιμή
Train size	4457
Test size	1115
TF-IDF features	5000
X_train shape	(4457, 5000)
X_test shape	(1115, 5000)

```
X_train shape: (4457, 5000)
X_test shape: (1115, 5000)
```

Σχήμα 6. Στιγμιότυπο με τα shapes του TF-IDF πίνακα.

3.2 Μοντέλα: Βασικά, Ensemble και Deep Learning

Εκπαιδεύτηκαν και συγκρίθηκαν τα παρακάτω μοντέλα:

- **Logistic Regression:** Γραμμικό μοντέλο-βάσης (baseline) που συχνά αποδίδει πολύ καλά σε προβλήματα κειμένου.
- **Multinomial Naive Bayes:** Κλασική προσέγγιση, ιδιαίτερα αποτελεσματική σε BoW/TF-IDF αναπαραστάσεις.
- **Random Forest:** Ensemble πολλών decision trees με bagging, που μειώνει το overfitting και βελτιώνει τη σταθερότητα.
- **XGBoost:** Boosting μέθοδος, όπου διαδοχικά δέντρα διορθώνουν λάθη προηγούμενων μοντέλων.
- **LSTM:** Νευρωνικό μοντέλο ακολουθιών, το οποίο επεξεργάζεται το κείμενο ως σειρά tokens.

Για τα μοντέλα μηχανικής μάθησης (Logistic Regression, Naive Bayes, Random Forest, XGBoost) χρησιμοποιήθηκαν τα TF-IDF χαρακτηριστικά.

Για το LSTM χρησιμοποιήθηκε tokenization και padding σε σταθερό μήκος ακολουθίας (100 tokens).

4. Αποτελέσματα: Μετρήσεις, γραφήματα και ανάλυση σφαλμάτων

Η αξιολόγηση πραγματοποιήθηκε με accuracy, precision, recall, F1-score και πίνακα σύγχυσης. Επιπλέον, εφαρμόστηκε Stratified 5-Fold Cross-Validation για πιο αξιόπιστη σύγκριση.

4.1 Αποτελέσματα σε hold-out test set (80/20):

Model	Accuracy	Precision(spam)	Recall(spam)	F1(spam)	TN	FP	FN	TP
Logistic Regression	0.9695	1.0000	0.7718	0.8712	966	0	34	115
Naive Bayes	0.9722	1.0000	0.7919	0.8839	966	0	31	118
Random Forest	0.9767	1.0000	0.8255	0.9044	966	0	26	123
XGBoost	0.9695	0.9259	0.8389	0.8803	956	10	24	125
LSTM	0.8664	0.0000	0.0000	0.0000	966	0	149	0

=== Logistic Regression Metrics ===

Accuracy : 0.9695

Precision: 1.0000

Recall : 0.7718

F1-score : 0.8712

=== Confusion Matrix (Logistic Regression) ===

	Pred ham (0)	Pred spam (1)
Actual ham (0)	966	0
Actual spam (1)	34	115

=== TP/TN/FP/FN (Logistic Regression) ===

TN (True Negatives) : 966

FP (False Positives): 0

FN (False Negatives): 34

TP (True Positives) : 115

=== Classification Report (Logistic Regression) ===

	precision	recall	f1-score	support
ham	0.97	1.00	0.98	966
spam	1.00	0.77	0.87	149
accuracy			0.97	1115
macro avg	0.98	0.89	0.93	1115
weighted avg	0.97	0.97	0.97	1115

=== Naive Bayes Metrics ===

Accuracy : 0.9722

Precision: 1.0000

Recall : 0.7919

F1-score : 0.8839

=== Confusion Matrix (Naive Bayes) ===

	Pred ham (0)	Pred spam (1)
Actual ham (0)	966	0
Actual spam (1)	31	118

=== TP/TN/FP/FN (Naive Bayes) ===

TN (True Negatives) : 966

FP (False Positives): 0

FN (False Negatives): 31

TP (True Positives) : 118

=== Classification Report (Naive Bayes) ===

	precision	recall	f1-score	support
ham	0.97	1.00	0.98	966
spam	1.00	0.79	0.88	149
accuracy			0.97	1115
macro avg	0.98	0.90	0.93	1115
weighted avg	0.97	0.97	0.97	1115

Σχήμα 7. Πίνακες σύγχυσης (Confusion Matrices) για τα μοντέλα Logistic Regression (αριστερά) και Naive Bayes (δεξιά).

Ανάλυση σφαλμάτων: Για spam filtering, ιδιαίτερη σημασία έχει ο έλεγχος των False Positives (ham που χαρακτηρίζονται ως spam) και False Negatives (spam που περνούν ως ham).

Στα πειράματα, ο Random Forest πέτυχε πολύ ισχυρό συνδυασμό υψηλού recall και μηδενικών false positives στο hold-out test set, ενώ ο XGBoost αύξησε το recall αλλά εμφάνισε $FP > 0$. Το LSTM απέτυχε να εντοπίσει spam (κατέρρευσε στην πλειοψηφική κλάση), γεγονός που αναδεικνύει τη δυσκολία των imbalanced δεδομένων.

4.2 Αποτελέσματα Cross-Validation (Stratified 5-Fold):

Model	Accuracy (mean ± std)	Precision (mean ± std)	Recall (mean ± std)	F1 (mean ± std)
Logistic Regression	0.963747 ± 0.003339	0.977134 ± 0.009267	0.746989 ± 0.019607	0.846616 ± 0.015456
Naive Bayes	0.971105 ± 0.003285	0.996565 ± 0.004209	0.787114 ± 0.022894	0.879383 ± 0.015237
Random Forest	0.977027 ± 0.001854	0.996923 ± 0.006154	0.831284 ± 0.017019	0.906460 ± 0.008725
XGBoost	0.971104 ± 0.004902	0.956659 ± 0.025600	0.821933 ± 0.017495	0.884109 ± 0.019397

	Model	Accuracy (mean)	Accuracy (std)	Precision (mean)	Precision (std)	Recall (mean)	Recall (std)	F1 (mean)	F1 (std)
0	Logistic Regression	0.963747	0.003339	0.977134	0.009267	0.746989	0.019607	0.846616	0.015456
1	Naive Bayes	0.971105	0.003285	0.996565	0.004209	0.787114	0.022894	0.879383	0.015237
2	Random Forest	0.977027	0.001854	0.996923	0.006154	0.831284	0.017019	0.906460	0.008725
3	XGBoost	0.971104	0.004902	0.956659	0.025600	0.821933	0.017495	0.884109	0.019397

Σχήμα 8. Σύγκριση μοντέλων σε cross-validation.

5. Συμπέρασμα: Ευρήματα και προτάσεις για μελλοντική εργασία

Υλοποιήθηκε πλήρης ροή ανίχνευσης spam:

1. Μελέτη δεδομένων
2. Καθαρισμός και lemmatization
3. TF-IDF χαρακτηριστικά και εκπαίδευση μοντέλων.

Με βάση cross-validation, τα ensemble μοντέλα υπερέχουν.

Ο **Random Forest** παρουσίασε την καλύτερη και πιο σταθερή απόδοση (υψηλότερο F1 και υψηλή precision/recall για spam).

Το **Naive Bayes** αποτελεί ισχυρό baseline για κείμενο, ενώ το **XGBoost** ήταν ανταγωνιστικό αλλά με χαμηλότερη precision και μεγαλύτερη μεταβλητότητα.

Το πείραμα **LSTM** δεν απέδωσε στη συγκεκριμένη ρύθμιση, αναδεικνύοντας ότι η deep learning προσέγγιση απαιτεί επιπλέον tuning, δεδομένα και τεχνικές.

Μελλοντική επέκταση της εργασίας:

- Ρύθμιση - threshold tuning με βάση ROC/PR curves.
- Χρήση προεκπαιδευμένων embeddings (GloVe/FastText) ή transformer-based μοντέλων (BERT) με fine-tuning.
- Περαιτέρω hyperparameter tuning για XGBoost/Random Forest και calibration πιθανοτήτων.
- Αντιμετώπιση ανισορροπίας με resampling (SMOTE/undersampling) και σύγκριση επιδόσεων.

Τελική επιλογή μοντέλου για το συγκεκριμένο dataset: Random Forest (με βάση cross-validation).